

Ethik für NLP Zusammenfassung

Contents

Einführung	4
Natural Language Processing	4
History	4
Öffentliche Diskussion	4
Dual Use	5
Ethik	5
Deontology	6
Consequentialism	6
Beispiele	6
Caveats	7
Belmont Report	7
KI	8
Natural Language Processing	8
Automation	8
Sprache	8
Deep Learning	9
Transfer Learning	9
Language modeling	9
Bi-Gram LM	10
Transformer	10
LLM bauen	10
Adversarial assessment	12
Bias	12
Menschen	12
Impliziter Bias	12
Folgen	12
Implicit Association Test (IAT)	13
Kahnemann / Tversky Model	13
Anchoring bias	13
Cognitive Bias	14
Cognitive Bias und Implicit Bias	14
Unbiased AI	15
Maschinen	15

Sources	16
Privacy	17
Probleme.....	17
General Data Protection Regulation (GDPR)	18
Profiling	18
Personal Data.....	18
Identifiers (Personally identifiable Information PII)	18
Sensitive Persönliche Daten	19
Pseudoanonymisierung	19
Anonymisierung	19
Sprachforensik.....	19
Privacy and NLP/AI.....	20
Datenanonymisierung.....	20
k-anonymity	20
l-diversity	21
t-closeness	21
Differential Privacy	22
Anonymisierung ohne Tabelle	23
Ontologie	23
Standards	24
KI Sicherheit.....	24
AI System	24
Capability estimation	24
Assumptions	25
Reproduzierbarkeit	25
Naiver Ansatz	25
Benchmarking.....	26
Menschliche Evaluation.....	26
Menschliche Tests wiederverwenden	27
Behavioral testing.....	28
Empfohlene Vorgehensweise	28
Emergent Capabilities.....	29
Model evolution	30
Feedback Effekte	30
Detection	31
Watermarking.....	31

Jailbreaking	32
AI Agents	33
KI Sicherheit verbessern.....	34
Regeln und Regularien	34
Research Ethics	34
Codes of Conduct / ACM Code of Ethics	35
GDPR	36
EU AI Act	37
Risikopyramide.....	37
NLP für das soziale Wohl	38
Impact.....	38
Good	39
Fact-Checking	39
Propaganda	40
Beispiele	41
Translational NLP	41

Einführung

- Sprache ist ein menschliches Kommunikationssystem mit vielen Funktionen
 - Information bewegen
 - Wissen erstellen oder speichern
 - Poesie
 - Sozialen Status kommunizieren
 - Usw.
- Sprache wird als Benchmark für die Intelligenz verwendet (Turing test)

Natural Language Processing

- Ziel sind Maschinen, die
 - Sprache verstehen können: **Barack Obama** is a former **president** of the **U.S.**
 - Wirklich Sprache verstehen können: It rained this morning _> The grass will be wet
 - Sprache verändern können: I would like a pretzel-> Ich hätte gerne eine Bretzel
 - Sprache produzieren können: Me: write a poem about ethics in AI Chatbot (1 second later): Sure!
 - In Sprache kommunizieren können
- NLP ist eine Technologie, die von Menschen geschaffen wurde und von Menschen genutzt wird, wie Internet, X-ray, Luftfahrt etc. Das kann für Gutes aber auch Schlechtes genutzt werden.

History

- 40s-50s: Maschinenübersetzung, Spielsysteme, DARPA
- 60s-80s: Semantik, Grammatik, Regelbasiert, wenig daten und teuer
- 90s-00s: Empirische Wende, große Sprachkörper, statistisches NLP, Suche
- 2010s: Deep Learning, Transfer Learning, Worteinbettung, End-to-End Systeme, Fundamentale Modelle (BERT, GPT)
- 2020s: Generative KI

Öffentliche Diskussion

- Offener Brief des Future of Life Institute: <https://futureoflife.org/open-letter/pause-giant-ai-experiments/>
 - KI-Systeme bergen erhebliche Risiken für die Menschheit
 - Fortgeschrittene KI sollte geplant und kontrolliert werden
 - KI-Systeme sollten nur entwickelt werden, wenn ihre Auswirkungen positiv sind
 - Das Training von KI-Systemen, die leistungsfähiger sind als GPT-4, sollte für mindestens 6 Monate ausgesetzt werden
- <https://aaai.org/working-together-on-our-future-with-ai/>
- Ja, KI-Systeme haben Vorteile und Risiken.
- Aber KI verbessert bereits jetzt unser tägliches Leben
- (Navigation, Krebsvorsorge, Empfehlungen ...).
- Wir arbeiten daran, Risiken, Fehler und Verzerrungen zu beseitigen.
- Ein kooperativer und wissenschaftlicher Ansatz unter Einbeziehung von zivilgesellschaftlichen Organisationen, Regierungen und Unternehmen ist erforderlich.

NLP/KI kann gut und schlecht genutzt werden, wie entscheiden wir, was gut und was schlecht ist? Forschung, Anwendung, Regulierung, Gesetze.

Large Language Models: Wahrscheinlichkeitsverteilung auf Text Sequenzen, dafür werden sie auf ganz vielen Texten trainiert, welche ethischen Implikationen kann so ein System haben?

- Plagiarismus: Ist der Text von einem Menschen geschrieben?
- Copyright: Model kann geschützten Inhalt generieren
- Datenschutzverletzung: Modell kann sensible Daten generieren
- Bias: Model kann schädliche Stereotypen übernehmen
- Black Box: Entscheidungen des Models sind nicht transparent
- Halluzination: Model kann falsche Informationen generieren
- Einfluss auf Jobs: Neue Technologien können Jobs ersetzen

Am Ende jeder NLP Anwendung sind Menschen, welche davon profitieren oder darunter leiden können.

„Ethics is a study of what are good and bad ends to pursue in life and what is right and wrong to do. An approach whose authority in practical thought is determined by reason rather than custom.“ - Introduction to Ethics, John Deigh

Ethik sind die guten und richtigen Dinge aber was ist gut und richtig? -> Trolley Dilemma

Beispiel Huhn Klassifizierer: Wenn Hahn, dann zu Essen verarbeiten, wenn Henne, dann lege Henne, Ethik ist eine innere Richtlinie, moralische Werte von Menschen und der Gesellschaft und diese sind nicht Schwarz/Weiß, außerdem verändern sich diese Wertevorstellung über diese Zeit. Legal bedeutet nicht gleich ethisch.

Der Huhn Klassifizierer ist ethisch einigermaßen okay, ein IQ Klassifizierer nicht. Weiteres schlechtes Beispiel „AI Gaydar“, Identifizierung der sexuellen Orientierung von Gesichtsmerkmalen. Problematisch, weil Menschen aufgrund ihrer sexuellen Orientierung immer noch verfolgt werden.

Fotos von Dating Website runtergeladen, legal ist nicht ethisch, öffentlich ist nicht gleich veröffentlicht, haben diese Menschen der Studie zugestimmt? Da nur weiße Menschen, welche ihre Orientierung selbst angegeben haben, aus bestimmten sozialen und alters Gruppen. Auch die Bilder sind selbst gewählt, auch wenn der Datensatz gleichverteilt ist aber die echte Klassenverteilung anders ist.

Dual Use


Wer ist verantwortlich? Wir müssen uns bewusst sein von unserem Real-World Impact unserer Forschung und die Beziehung zwischen Ideen und Konsequenzen verstehen.

Nur weil wir etwas können, heißt es nicht, dass wir auch sollten.

Es ist wichtig, KI Systeme defensiv zu bewerten.


Ethik

Menschen haben Absichten, treffen Entscheidungen und ergreifen Maßnahmen. Diese Maßnahmen haben einen moralischen Wert.



Wie macht man das richtige? Warum sind manche Maßnahmen gut und andere schlecht?

- Weil wir es halt so tun
- Weil unsere Religion es so vorschreibt, Religion reflektiert meistens das Überleben der eigenen Gemeinschaft
- Weil es legal ist



In der Ethik wird betrachtet, wie Menschen handeln sollten, nicht wie sie tatsächlich handeln.

- Normative Ethik: Wie entscheidet man generell, was gut ist
- **Angewandte Ethik:** Was ist gut in einer bestimmten Situation
- Metaethik: Was ist Moral, können moralische Werte objektiv existieren.

Ethik ist ein Zweig des Wissens, welcher sich mit den moralischen Prinzipien beschäftigt, es ist abweichend von Gesetzen und Religion

Deontology

Die Deontologie (Pflichtethik) beschreibt, dass eine Aktion moralisch gut ist, wenn sie den Regeln folgt. Die Regeln sind universale moralische Gesetze, welche häufig mit Immanuel Kant in Verbindung gebracht werden.

Consequentialism

Der Konsequentialismus (Folgenethik) beschreibt, dass eine Aktion moralisch gut ist, wenn das Ergebnis gut ist. Utilitaristische Sichtweise (Jeremy Bentham): Das größte Wohl für die meisten Menschen

Beispiele

Tuskegee Syphilis Experiment

- 40 Jahre lange Studie der US-Gesundheitsorganisation mit Beginn 1932, mit dem Ziel, den Verlauf von nicht behandelter Syphilis zu beobachten.
- 600 afrikanische Landwirte, 399 mit Syphilis, 201 ohne.
- Diesen wurde gesagt, dass sie für „schlechtes Blut“ behandelt werden, ihnen und ihren sexuellen Partnern wurde nicht mitgeteilt, dass sie Syphilis haben, auch als Penicillin als Medikament eingeführt wurde, wurde es den Betroffenen nicht mitgeteilt.
- 1964 gab es ein Protestschreiben eines Arztes, welches von den Autoren 1965 nicht beantwortet wurde, weil es angeblich der erste Brief in diese Richtung war.
- 1966 wird das US-Zentrum für Krankheitskontrolle informiert aber die Studie geht weiter
- Erst als Peter Buxtun 1972 damit zur Presse geht, stoppt die Studie 1974

Stanford Prison Experiment

- Philip Zimbardo, Stanford University, August 1971

- Eine Fortsetzung des berühmten Milgram-Experiments: „Menschen können grausam sein, auch ohne Befehl von oben.“
- Ziel: Testen, wie sich wahrgenommene Macht auf die Probanden auswirkt
- College-Studenten wurden ausgewählt, um entweder „Gefangene“ oder „Wachen“ zu sein
- Die „Wachen“ wählten Uniformen aus und legten die Disziplin fest
- Den Teilnehmern wurde nicht klar gesagt, dass sie das Experiment verlassen können.
- Die für zwei Wochen geplanten Experimente mussten nach sechs Tagen abgebrochen werden
- Ergebnis: Wachen demütigten und misshandelten Gefangene. Gefangene wurden entmenslicht. Beweis für die „hässliche Seite der menschlichen Natur“.
- Aber Studie gelangt an die Presse noch bevor sie veröffentlicht wird.
- Das Experiment war ethisch fragwürdig, methodisch fehlerhaft und brachte keinen Nutzen, der das verursachte Leid der Teilnehmenden rechtfertigte.


Das Ergebnis: Ethische Regularien für Forschung: Nuremberg Code, Belmont Report, National Research Act, Ethische Versammlungen, Code of Conduct. Für viele waren die o.g. Studien damals in Ordnung, da diese vor allem westlich geprägt waren.

Caveats

Ethische Urteile sind zeitabhängig

Ethische Urteile sind kulturabhängig

- Das „Moral Machine“ Experiment, einlenken oder nicht einlenken.
- 39.61 Millionen Einschätzungen
- Einschätzungen von vielen Verschiedenen Ländern
- Das Ziel ist universale Maschinenethik (oder dessen Hindernisse)
- Das Experiment zeigt, dass z.B. eher Menschen als Tiere verschont werden und dass die Einschätzungen stark von der Nationalität abhängen.
- <https://www.moralmachine.net/>



Belmont Report

Der Belmont Report wurde 1979 veröffentlicht und dient als grundlegendes Dokument in der Ethikforschung

- Forschung ist eine Aktivität, die darauf ausgelegt ist, eine Hypothese zu testen, es erlaubt Schlüsse zu ziehen und generalisiertes Wissen zu entwickeln und beizutragen
- Ein Menschliches Subjekt ist ein lebendes Individuum, über das ein Forscher Informationen bekommt oder generiert durch Intervention oder Interaktion mit dem Individuum und benutzt, studiert oder analysiert diese Informationen
- Das Menschliche Subjekt ist dabei unabhängig davon, ob es ein Student, ein Ausländer, eine arme Person oder eine Person im Internet ist. Jeder hat die gleichen Rechte

Grundprinzipien:

1. Respekt für Personen: Individuen sollten als autonome Agenten behandelt werden (Informierte Zustimmung). Personen mit eingeschränkter Selbstständigkeit haben Anspruch auf Schutz (Kinder, Senioren, Gefangene, Menschen mit Behinderung).
2. Beneficence (Wohltätigkeit): Keinen Schaden zufügen, Nutzen maximieren, Risiken minimieren. Benötigt eine vorsichtige Risiko-Nutzen Analyse.
3. Justice (Gerechtigkeit): Faire Verfahren bei der Auswahl von Forschungsteilnehmern. Die Fortschritte sollten allen zugutekommen.

Der Belmont Report ist ein guter Startpunkt für Forschungsethik. Medizinische Ethik, Business Ethik etc. haben eigenen Prinzipien und Guidelines.

KI

KI wird von Menschen entwickelt und eingesetzt, dies beinhaltet viele Aktionen und Entscheidungen, sind diese ethisch?

Beispiel: "I develop an LLM. I employ annotators to filter unsafe content from my training data. This allows me to protect future users from potential harm"

KI ist eine Entscheidungs-Treffende Technologie, siehe Moral Machine.

Was sind die Vorteile und Risiken von KI-Systemen? Dafür müssen wir verstehen, die KI-Systeme arbeiten. KI ist entwickelt und trainiert von Menschen, wir müssen also auch verstehen, wie Menschen funktionieren. KI ist in der Gesellschaft angewandt, also müssen wir auch verstehen, wie die Gesellschaft funktioniert.

Wie können wir Vorteile maximieren, Schaden minimieren und große Fehler vermeiden.

Natural Language Processing

Automation

Automation ist das Verwenden von Maschinen oder Computern anstelle von Menschen, um eine Aufgabe zu erledigen. Dies kann physische Arbeit, eine Fähigkeit oder auch Entscheidungen treffen sein im Falle von KI.

KI ist eine potenziell transformative Technologie mit Einfluss auf viele verschiedene Felder.

Man muss betrachten, wem diese Technologie hilft oder schadet, ob Daten repräsentativ oder sensibel sind. Es ist notwendig zu verstehen, wie KI-Systeme arbeiten. Das Problem ist, dass KI eine Art menschliche Intelligenz impliziert, allerdings unterscheidet sich die Maschinenintelligenz entscheidend von menschlicher Intelligenz.

Sprache

Siehe

Einführung

Geschichte:

- Regelbasierte Systeme, keine Daten, keine Berechnung
- Statistisches NLP, mit Daten
- Neuronale Netzwerke, mit Berechnung und Geld
- End-to-End Systeme (2010s), mit mehr Daten und mehr Berechnung
- Language models (2015s), noch mehr Daten und Berechnungen
- Large Language models, unglaublich viele Daten und Berechnungen


Deep Learning

Regelbasierte Systeme brechen schnell zusammen, benötigen Experten und hat unzureichende Abdeckung, können aber unter bestimmten Umständen noch nützlich sein.

Bei maschinellem Lernen werden diese Regeln aus den Daten gelernt.

- Daten werden in Features transformiert, dann wird eine Funktion aus den Features gelernt. Dies benötigt aber immer noch Feature Engineering und benötigt daher Experten und hat auch unzureichende Abdeckung.
- Beim Deep Learning werden auch direkt die Features gelernt.

Jeder Knoten ist ein „Neuron“ welches ein Signal basierend auf seinem Input und seiner Aktivierungsfunktion ausgibt. Jede Kante hat ein Gewicht, diese Gewichte werden mittels Backpropagation mithilfe einer Loss Funktion gelernt.



Transfer Learning

Menschen lernen so schnell, da sie auf vorheriges Wissen zurückgreifen können.

Dieses Prinzip wird auch beim Transfer Learning angewandt. Ein Modell wird auf einer Aufgabe vortrainiert und danach mit dem Wissen einer anderen Aufgabe getuned.

Die Daten für das zuerst trainierte Modell müssen viele sein und die Aufgabe muss relevant und möglichst generell sein.




Language modeling

Distributional hypothesis: Die Bedeutung eines Wortes kann durch seinen Kontext ermittelt werden. Wenn wir also das richtige Wort zu einem gegebenen Kontext vorher sagen, haben „Sprache gelernt“.

Beim Language Modelling wird ein Wort in einem text versteckt und dieses dann wieder vorhergesagt. Diese Aufgabe gibt es schon lange vor neuronalen LMs und eignet sich gut als Pre-training Aufgabe, da sie quasi unendlich Daten hat und keine labels benötigt.

Ein Language Model ist die Wahrscheinlichkeitsverteilung von Text.

Use Case 1: Wahrscheinlichkeit einer Textsequenz berechnen.



Use Case 2: Text Vervollständigung/ Generierung.



Bi-Gram LM

Simple, nicht-neurales „Bi-Gram“-Language Model: Wahrscheinlichkeit von Token-Paaren

Der nächste Token wird basierend auf den konditionalen Abhängigkeiten generiert.



Problem: Jedes Wort ist nur vom direkten Vorfahren abhängig, es fehlt die Konsistenz über lange Textsequenzen. Es können keine Worte verarbeitet werden, die unbekannt sind und dieses Model hat eine schlechte Repräsentation von Wortbedeutung (Semantik).

Transformer

Transformer sind seit 2017 die Modelle für LMs und LLMs. Sie zeichnen sich aus durch eine Multi-Layer Struktur mit einem Attention Mechanismus, Positionalen Embeddings und Subword Embeddings. Im Kern sind sie aber immer noch einfach ein gutes Language Model.

LLM bauen

Schritt 0: Base Modell

- Daten sammeln und filtern
- LM (typischerweise Transformer) trainieren, welches das nächste Wort vorhersagt

Schritt 1: Instruction tuning

- Moderne LMs sind nicht nur darauf trainiert Sequenzen fortzuführen, sondern auch auf Code, Markup etc.
- Das Modell wird weiter trainiert, um Anweisungen zu folgen, gegeben einer Anweisung, produziere eine plausible Antwort.
- Diese Anweisungen können Manuell sein (einfache Dialoge, Fragen und Antworten)
- Die Anweisungen kommen zunächst von u.a. Menschen, synthetischen Daten oder bestehende Datensets, die in einem Anweisung-Antwort Format vorliegen.
- Nach dem deployen kommen die Anweisungen von den Endnutzern.

Schritt 2: RLHF


- Das Modell soll etwas tun und dabei Regeln befolgen, um z.B. schadhaftes Verhalten zu unterbinden.
- Hierfür verwendet man Reinforcement Learning, um die Performanz und das Befolgen von Regeln zu verbessern.

Reinforcement Learning:

1. Model generiert mehrere Antworten zu einer Anweisung
2. Mensch ordnet diese Antworten durch Paarweisen Vergleich von gut zu schlecht
3. Ein separates Belohnungsmodell trainieren, um dieses Rating vorherzusagen.
4. Dieses Belohnungsmodell verwenden, um das LLM zu fine-tunen.

Schritt 3: Extras


- Input Preprocessing: Filter, um Sicherheit zu verbessern
- Output Post-Processing: Überprüfen, dass das Output zu einem bestimmten Format, z.B. JSON passt
- GUI, user Feedback Module
- APIs, Plugins, Historie / Memory



LLMs zu trainieren ist ein großer Aufwand, was kann unser LLM nun?

- Prompting
- In-context Learning: Dem Modell ein paar Beispiele geben, um die Performanz für eine bestimmte Aufgabe zu steigern.
- Begründung und Planung
- Code Generierung
- LLM kann Code generieren, also auch API anfragen und diese ausführen. Da LLMs manchmal schlecht in Mathe sind, kann man eine Rechner API anfragen oder wenn das Wissen veraltet, ist eine Newsfeed API
- Kommandos geben, um mit der Umgebung zu interagieren
- Erinnerung und langfristige Ziele hinzufügen
- Dies führt zu **autonomen Agenten**
- Viele angewandte Aufgaben, Grammatikkorrektur, Umschreiben und bearbeiten, Ideen Generierung und Brainstorming, Multimodale Anwendungen, usw.

Adversarial assessment



Bias

Menschen

Impliziter Bias

Der Implizite Bias ist ein übergeneralisierter Eindruck über eine bestimmte Gruppe von Personen (Frauen und Männer, Alt und Jung, Professor und Athlet). Diese können negativ oder positiv sein.

Der implizite Bias unterscheidet sich vom expliziten Bias. Der explizite Bias wird direkt ausgedrückt und die Person ist sich dessen bewusst, also z.B. Offener Rassismus, Sexismus, ...

Der Implizite Bias wird nicht direkt ausgedrückt und die Person ist sich dessen eventuell unbewusst.

Menschen haben eine innere Tendenz dazu Dinge in der Welt zu kategorisieren und diese gelernten Informationen in mentalen Repräsentationen (Schemas) zu speichern. Diese

gespeicherten Informationen werden automatisch aktiviert, wenn man etwas aus einer Kategorie trifft.

Folgen

Micro-inequities: Verdeckte, unbeabsichtigte, häufig nicht erkannte Ereignisse, die Machtverhältnisse oder die Wahrnehmung von „Unterschieden“ verstärken.

Microaggression: Die Stimmung an der Oberfläche kann negativ, neutral oder positiv sein.

“A comment or action that subtly and often unconsciously or unintentionally expresses a prejudiced attitude towards a member of a marginalized group” - Merriam Webster

Weitere Folgen: Einstellungsentscheidungen, Polizei und Gerichtsentscheidungen, Selbstwahrnehmung, Medizinische Versorgung, Finanzielle Beratung

Implicit Association Test (IAT)

Entscheidungen treffen (durch Drücken einer Taste auf der Tastatur), um Wörter oder Bilder zu kennzeichnen, die zu einer von zwei gleichzeitig dargestellten Kategorien gehören (z. B. Bilder von Afroamerikanern oder Europäischstämmigen Amerikanern kategorisieren und positive/negative Adjektive kategorisieren).

Der Test vergleicht die Reaktionszeiten, wenn verschiedene Kategorienpaare die gleiche Reaktions-Taste teilen.

Um Fehler zu vermeiden, wie „linke Hand ist langsamer als die Rechte“ wird die Reihenfolge auch getauscht.

Die Reaktionszeit wird unter verschiedenen Bedingungen erfasst.

Wenn die Teilnehmer eine Assoziation zwischen zwei Wörtern haben (z. B. „Weiß + GUT“), reagieren sie schneller und genauer. Wenn keine Assoziation besteht, reagieren sie langsamer und machen Fehler. Sie „verzögern“ das Drücken der Taste.

Der IAT ist eine Methode um impliziten Bias zu messen, er ist nicht perfekt, aber weit verbreitet. Der Test dauert im Normalfall 10-30 Minuten und kann zum Beispiel online beim Project Implicit gemacht werden auf viele verschiedene Kategorien.

Implizite Vorurteile sind allgegenwärtig und unbewusst und beeinflussen die Art und Weise, wie wir andere sehen und behandeln, selbst wenn wir entschlossen sind, fair und objektiv zu sein.

Kahnemann / Tversky Model

Das Modell von Kahneman und Tversky unterscheidet zwischen zwei Arten des Denkens:

System 1 arbeitet schnell, automatisch, mühelos und intuitiv. Es nutzt gelernte Assoziationen und ist für Routinen oder einfache Entscheidungen zuständig (z. B. „Rot heißt Stop“ oder 2×5).

System 2 ist hingegen langsam, kontrolliert, bewusst und benötigt geistige Anstrengung. Es wird aktiviert, wenn komplexere, neue oder ungewohnte Aufgaben gelöst werden müssen (z. B. 172×520).

Im Alltag arbeiten beide Systeme zusammen – System 2 kann neue Regeln einführen, die später von System 1 automatisiert übernommen werden.

- Unser Gehirn ist evolutionär darauf ausgerichtet, Informationen schnell abzurufen und automatische Beurteilungen vorzunehmen.

- Wir identifizieren uns mit System 2, aber tatsächlich werden über 95 % der kognitiven Prozesse vom System 1, dem „Autopiloten“, übernommen
- Beide Systeme sind für ihre jeweiligen Aufgaben nützlich
- Wenn jedoch jemand System 1 einsetzt, wo er eigentlich System 2 einsetzen sollte, entsteht ein Problem


Anchoring bias

Der Anchoring Bias oder Fokalismus ist die Tendenz, sich bei Entscheidungen zu stark auf ein Merkmal oder eine Information zu verlassen – sie zu „verankern“ (in der Regel die erste Information, die zu diesem Thema gewonnen wurde).

Cognitive Bias

- Systematisches Muster der Abweichung vom rationalen Urteilsvermögen (System 2) „Wo wir System 2 verwenden sollten, aber System 1 verwenden“
- Rationales Urteilsvermögen = basiert auf Fakten und Logik
- Systematisch = kein einmaliges Ereignis, sondern ein klar beobachtbarer Effekt bei vielen Menschen und in vielen Situationen
- Umfangreich untersucht in Psychologie, Soziologie und Verhaltensökonomie
- Es gibt viele verschiedene Cognitive Biases:

https://en.wikipedia.org/wiki/List_of_cognitive_biases



DESIGNHACKS.CO · CATEGORIZATION BY BUSTER BENSON · ALGORITHMIC DESIGN BY JOHN MANOOGIAN III (JM3) · DATA BY WIKIPEDIA

© creative commons 10 attribution · share-alike

Cognitive Bias und Implicit Bias

- Cognitive bias + society = implicit bias
- Confirmation bias: mehr Aufmerksamkeit auf Informationen zu richten, die bereits bestehende Überzeugungen bestätigen, und gegenteilige Beweise zu ignorieren
- Ingroup favoritism: Gruppenmitglieder gegenüber Nicht-Gruppenmitgliedern bevorzugen
- Group attribution error: Verallgemeinerungen über eine Gruppe auf der Grundlage einer Gruppe von Vertretern
- Halo effect: Verwenden Sie den Gesamteindruck einer Person, um ihre spezifischen Eigenschaften
- **Implizite Vorurteile sind kulturell** bedingt und hängen von Ort und Zeit ab. Wahrscheinlich nehmen Sie den Unterschied zwischen „Adligen und Bürgern“ gar nicht wahr. Oder die Akzentunterschiede in einem weit entfernten Land (die für die Menschen in diesem Land von großer Bedeutung sind).
- **Kognitive Verzerrungen sind universell**, sie betreffen die Art und Weise, wie Menschen die Welt verarbeiten. Kognitive Verzerrungen sind der zugrunde liegende Mechanismus impliziter Verzerrungen. Aber sie sind viel umfassender.

Unbiased AI

- NLP- und KI-Systeme werden von Menschen entwickelt.
- Sie werden anhand von Daten von Menschen trainiert und von Menschen bewertet.
- Sie werden von Menschen verwendet.
- Menschen sind voreingenommen.
- KI wird voreingenommen sein! Wenn wir nicht aufpassen.

Maschinen

Das ideale Verhalten: Wenn Alter für die Aufgabe irrelevant ist, dann soll das System nicht mittels Alter diskriminieren. Aber wenn es für die Aufgabe relevant ist, darf danach diskriminiert werden. Das ideale Verhalten ist also Aufgabenabhängig und Abweichungen vom idealen Verhalten können in verschiedenen Facetten auftreten.

Toy Example: Targeted Advertising

- Ein Web-Publisher möchte gezielt Software Engineers (SWE) mit Werbung ansprechen → Klassifikator wird trainiert.
- **Input:** Nutzerdaten (Browsing, Sprache, Standort, Alter, Interessen, Geschlecht...)
- **Output:** SWE vs. non-SWE.
- Obwohl die **Precision** für Männer und Frauen gleich ist (80 %), unterscheidet sich die **Recall** → Frauen, die SWE sind, werden deutlich seltener erkannt ⇒ ungleiche Chancen → unfair für bestimmte Gruppen.

Real Example: COMPAS (Northpointe vs. ProPublica)

- System zur Vorhersage zukünftiger Straftaten als Entscheidungshilfe für Richter.
- Laut Hersteller: kein „Race“-Feature, balancierte Trainingsdaten.
- In Wirklichkeit korrelieren andere Merkmale (z. B. Postleitzahl) mit Rasse → Trainingsdaten und Zielgröße spiegeln gesellschaftliche Vorurteile wider.
- → Höhere False-Positive-Rate für nicht-weiße Personen ⇒ diskriminierende Ergebnisse.

Sprache & Diversität

- Menschen unterscheiden sich in Sprache je nach u. a. Geschlecht, Alter, Herkunft, Bildung, Dialekt...
- ML-Modelle wurden oft mit homogenen Datensätzen trainiert, z. B. WSJ-Corpus (weiße, gebildete, männliche native Speaker) → gute Performance **nur** bei ähnlichen Texten.
- Folge: schlechtere Leistung für andere Gruppen (Dialekte, junge Sprache, andere Themen...).

Was bedeutet Bias bei ML-Klassifikatoren?

1. **Different outcomes:** Verteilung der Vorhersagen unterscheidet sich zwischen Gruppen (z. B. strengere Strafen für bestimmte Ethnien).
2. **Different performance:** Fehlerverteilung unterscheidet sich zwischen Gruppen (z. B. Sprachassistent funktioniert schlechter bei Akzent).
3. **Different safety:** Sicherheitsmaßnahmen sind für bestimmte Gruppen weniger wirksam, z. B. sind LLM eher bereit, schädliche Anfragen für Nicht-Muttersprachler zu erfüllen.

Ein NLP/ML-System ist voreingenommen, wenn es sich gegenüber Personen mit unterschiedlichen Eigenschaften unterschiedlich verhält, obwohl es eigentlich so konzipiert sein sollte, dass es sich gegenüber allen Personen gleich verhält.

Um für ein Black-Box AI System zu testen, ob es Vorurteile hat, muss man 2 Schritte machen:


1. Attribut wählen und Ideales Verhalten definieren. Dabei muss man Attribute beachten von Menschen, die das System nutzen und vom System verarbeitet werden.
2. Experiment ausführen: Gruppen anhand der Attribute bilden und dann Systemverhalten zwischen diesen Gruppen vergleichen (Predictions, Error rate, Safety, ...). Wenn das System zwischen den Gruppen verschiedenes Verhalten aufweist, hat man einen Bias gefunden.

Sources

1. **Label bias:** KI Systeme lernen von menschlichen Entscheidungen, menschlichem Feedback, Annotationen und historischen Daten. Menschliche Entscheidungen sind von Bias betroffen, natürlichem kognitiven und impliziten Bias und mangelnde Fachkenntnisse, Anstrengung und Heuristik.
 - a. **Lösung:** Wenn historische Entscheidungen als Trainingsdaten genutzt werden, müssen diese zuvor auf mögliche Verzerrungen geprüft werden. Bei menschlicher Annotation sollte die Aufgabe klar formuliert, die Annotierenden geschult und der Prozess transparent dokumentiert werden (inkl. Richtlinien, Herkunft der Daten und Demographie der Annotatoren), um Bias zu reduzieren.
2. **Sample bias:** Auch bekannt als Selektions bias. Lücke zwischen der bei der Entwicklung berücksichtigten Population (Textautoren, Kommentatoren, Tester) und der tatsächlichen Nutzerpopulation. Unterschiede in Sprache und Verhalten
 - a. **Lösung:** Man sollte früh verstehen, mit welchen Nutzergruppen und Daten das System arbeiten wird und diese möglichst repräsentativ in Entwicklung und Test berücksichtigen; fehlen Daten für bestimmte Gruppen, müssen sie gezielt gesammelt oder erweitert werden – und der gesamte Datenprozess transparent dokumentiert werden.

3. **Amplification bias:** Moderne KI-Modelle neigen zu Heuristiken. Wenn es eine Abkürzung gibt, wird das Modell diese nutzen. Verstärkung der bereits in den Daten vorhandenen Verzerrungen.
 - a. **Lösung:** Überprüfe, ob das System bestehende Ungleichheiten verschärft, und gleiche Daten ggf. durch Gruppenzuordnungen, balanciertes Sampling oder synthetische Beispiele aus; beim Training sollte zudem eine Regularisierung eingesetzt werden, die sowohl Leistung als auch faire Verteilung berücksichtigt.
4. **Semantic bias:** Die meisten modernen NLP-Systeme basieren auf dichten Sprachdarstellungen, die aus großen Mengen von Webdaten abgeleitet werden (Embeddings, LMs, LLMs). Ähnliche Worte sind näher beieinander. Diese Repräsentationen haben latente Biases. Unterschied zu Selection Bias: Die Sprache selbst ist das Problem.
 - a. **Lösung:** Wähle ein weniger verzerrtes Pretraining-Korpus bzw. Embedding und passe die Embeddings gezielt an, indem man bestimmte Wortpaare enger bzw. weiter auseinander zieht (Retrofitting), ohne das übrige Vektorraumssystem stark zu verändern.
5. **Design bias:** Man kann zwar argumentieren, dass ein Modell für bestimmte Nutzergruppen nicht gedacht ist, aber viele Gruppen werden generell von NLP-Anwendungen weniger unterstützt, weil sie in Datensätzen und bei der Entwicklung kaum berücksichtigt werden. Entwickler*innen sind ebenfalls von Bias betroffen und arbeiten oft an Anwendungen für Gruppen, denen sie selbst angehören – vor allem im Englischen –, was einen Feedback-Loop erzeugt: bessere Produkte für dominante Gruppen führen zu mehr Daten und zu noch besseren Produkten für genau diese Gruppen.
 - a. **Lösung:** Reflektiere, für wen die Technologie gedacht ist und ob sie wirklich denjenigen zugutekommt, die sie am dringendsten brauchen; sprich mit Betroffenen, arbeite an Anwendungen für unterrepräsentierte Gruppen und konzentriere dich auf Aufgaben mit breitem gesellschaftlichem Nutzen.

Mehrere Biases können Kombiniert werden. Bias selbst ist nicht gut oder schlecht, es ist nur eine Eigenschaft eines Systems, Daten, Menschen. Schlecht ist die Voreingenommenheit, die ungeprüft und undokumentiert ist und eine Entscheidung beeinflusst, bei der es keine Voreingenommenheit geben sollte.



Privacy

Menschen produzieren Daten über sich selbst. Diese Daten können für Gutes oder Schlechtes genutzt werden.

Privatsphäre ist die Fähigkeit einer Person oder Gruppe, sich selbst oder Informationen über sich selbst abzusichern und sich dadurch selektiv auszudrücken.

- Territorial privacy: Öffentlicher vs Privater Raum
- Personal privacy: Gesehen werden vs Beobachtet werden
- **Information privacy:** Gesehen werden vs Beobachtet werden vs Getracked werden

Probleme

1. Information privacy paradox: Inkonsistenz von Privacy Attributen und Privacy Verhalten. Menschen sind sehr besorgt über Ihre Privacy aber teilen ihre persönlichen Daten schnell.
2. Ist Privacy eine persönliche Entscheidung?: Wie kann das Teilen von Daten andere beeinflussen? Freunde, durch teilen von Kontakten, Angehörige durch DANN, Organisationen durch zB Location Apps, Generelles menschliches Verhalten.
3. Potenzielle Nutzung ist schwer vorherzusagen: Vor allem wenn Daten mit dritten geteilt werden.
4. Kulturelle Unterschiede: Der „gesunde Menschenverstand“ unterscheidet sich je nach Kultur, man benötigt gemeinsame Grundlagen.

General Data Protection Regulation (GDPR)

Daten müssen proaktiv geschützt werden.

Die GDPR beobachten die Verarbeitung von Daten von Organisationen und verhängt hohe Geldstrafen bis 20 Millionen Euro oder 4% des globalen Gewinns.

Die GDPR basiert auf der europäischen Konvention für Menschenrechte: „Jeder hat das Recht auf Achtung seiner Privatsphäre, seinem Zuhause und seiner Korrespondenz.“

Beispiele wie Daten geschützt werden können:

- Recht auf Information: Eine Person sollte wissen, welche Daten erfasst werden und wie diese verwendet werden.
- Recht auf Vergessenwerden: Eine Person kann die Löschung ihrer Daten beantragen.
- Minimierung der Verarbeitung: Das Unternehmen sollte nur die für die Erfüllung der Aufgabe erforderlichen Mindestdaten erfassen und diese löschen, sobald sie nicht mehr benötigt werden...

Profiling

Profiling ist jede Form der automatisierten Verarbeitung personenbezogener Daten, die darin besteht, dass personenbezogene Daten verwendet werden, um bestimmte Aspekte in Bezug auf eine natürliche Person zu bewerten, insbesondere um Aspekte in Bezug auf die Arbeitsleistung, die wirtschaftliche Lage, die Gesundheit, die persönlichen Vorlieben, die Interessen, die Zuverlässigkeit, das Verhalten, den Aufenthaltsort oder die Bewegungen dieser natürlichen Person zu analysieren oder vorherzusagen.

Personal Data

Personenbezogene Daten sind alle Informationen, die sich auf eine identifizierte oder identifizierbare natürliche Person beziehen.

Identifiers (Personally identifiable Information PII)

Die Person wird identifizierbar, wenn sie direkt oder indirekt identifiziert werden kann.

- Gängige Identifier: Name, Geburtsdatum, E-Mail, Adresse, Aussehen, ...
- Aber auch: Führerscheinnummer, Bankkartennummer
- Manchmal sogar: IP-Adresse, Arbeitszeiten, Ortsdaten, ...

87% der US Einwohner können mit nur 3 Dimensionen identifiziert werden.


Sensitive Persönliche Daten

Einige personenbezogene Daten sind besonders sensibel und unterliegen einem höheren Schutz.

Genetische Daten, Biometrische Daten, Gesundheitsdaten, Rassen- und ethnische Herkunft, Sexuelle Orientierung, Politische Meinung, Religiöse und ideologische Überzeugungen.

Aggregation über Aktivitäten, verringert den Datenschutz: Profilerstellung, Nachverfolgung, individuelles Verhalten

Aggregation über Personen, verbessert den Datenschutz: Statistiken, Trends, allgemeines Verhalten



Pseudoanonymisierung

Pseudonymisierung: Eine Person kann anhand der Daten ohne zusätzliche Informationen nicht identifiziert werden, vorausgesetzt, diese zusätzlichen Informationen werden sicher aufbewahrt.

Vorbehalt: Mit zusätzlichen Informationen kann die Person identifizierbar werden!

- Verschlüsselung – es gibt irgendwo ein Passwort, wenn wir es kennen, können wir die Person identifizieren
- Platzhalter – können die Person anhand anderer Informationen oder anhand von Wissen über die Zugehörigkeit der Person zum Datensatz erneut identifizieren

Pseudonymisierte Daten bleiben personenbezogene Daten.

Anonymisierung

Anonymisierung: Eine Person kann nicht identifiziert werden, von niemandem, zu keinem Zeitpunkt, egal wie viele zusätzliche Informationen wir haben.

Schwer zu erreichen und zu garantieren. Außerdem ist es kein binärer Wert aber es gibt Wege ihn zu quantifizieren, z.B. Generelle Statistik auf eine genügend große Bevölkerung.

Das Fehlen personenbezogener Daten bedeutet nicht, dass die verbleibenden Daten keine Identifizierung von Personen ermöglichen. Bei 8 Milliarden Menschen reichen bereits 35 Ja/Nein Fragen um jede Person eindeutig zu identifizieren.

Modelle können aus scheinbar harmlosen digitalen Spuren wie Likes oder Sprachverwendung sehr genaue Rückschlüsse auf sensible persönliche Eigenschaften ziehen (z. B. politische

Einstellung, sexuelle Orientierung, Persönlichkeit), was große Risiken für Privatsphäre und Diskriminierung birgt. Daher müssen solche Systeme kritisch hinterfragt und durch geeignete Datenschutzmaßnahmen wie Anonymisierung oder gesetzliche Vorgaben begrenzt werden.

Sprachforensik

- Anwendung von linguistischen Profiling-Verfahren bei strafrechtlichen Ermittlungen
- Abgleich anonymer Texte mit Verdächtigen. Lösegeldforderungen, anonyme Drohungen ...
- Identifizierung des Verfassers: Wer hat dieses (Teil-)Dokument verfasst? Rechtsstreitigkeiten usw.
- Profiling: Was sagt uns der Text über den Verfasser? Hintergrund, Ausbildung ...
- Von: Schreibstil, Sprachmuster, Themen

Privacy and NLP/AI

Forschung:

- Um Vorurteile zu testen, müssen wir Menschen nach Geschlecht, Alter, sozialer Schicht usw. gruppieren.
- Medizinische Anwendungen, Polizei Anwendung,...

Entwicklung:

- Personalisierung
- Irgendwo im großen LLM-Korpus WERDEN personenbezogene Daten in Textform enthalten sein.

Deployment:

- Benutzer werden ihre eigenen personenbezogenen Daten und die anderer Personen an Ihr KI-System übermitteln.

Verletzungen der Privatsphäre sind ein Risiko, das gemanagt und gemindert werden muss.

Datenanonymisierung

Datentabelle sind das gängigste Format für die Datenaggregation. Aus den aggregierten Statistiken lassen sich viele nützliche Erkenntnisse gewinnen.

Wichtig: Die Aggregation pro Benutzer verletzt die Privatsphäre. Die Aggregation über mehrere Benutzer hinweg fördert den Datenschutz (wenn sie richtig durchgeführt wird).

Anonymisierung der Tabelle mit dem Ziel die Verwendbarkeit zu erhalten.

- Input: Gegeben sei eine Tabelle mit Daten, die Merkmale und Werte enthält.

- Output: Daten veröffentlichen, die garantieren, dass Einzelpersonen nicht identifiziert werden können

Zwei zentrale Methoden:

- Suppression: Löschen Sie die Einträge, die zu „einzigartig“ sind.
- Generalisierung: Die Genauigkeit einiger Felder lockern, zum Beispiel Stadt zu Region, Alter zu Altersgruppe.



Name	Age	Gender	State of domicile	Religion	Disease
*	20 < Age ≤ 30	Female	Tamil Nadu	*	Cancer
*	20 < Age ≤ 30	Female	Kerala	*	Viral infection
*	20 < Age ≤ 30	Female	Tamil Nadu	*	TB
*	20 < Age ≤ 30	Male	Karnataka	*	No illness
*	20 < Age ≤ 30	Female	Kerala	*	Heart-related
*	20 < Age ≤ 30	Male	Karnataka	*	TB
*	Age ≤ 20	Male	Kerala	*	Cancer
*	20 < Age ≤ 30	Male	Karnataka	*	Heart-related
*	Age ≤ 20	Male	Kerala	*	Heart-related
*	Age ≤ 20	Male	Kerala	*	Viral infection

k-anonymity

k-anonymität ist eine Eigenschaft eines Datensatzes

Ein Datensatz weist k-Anonymität auf, wenn die Informationen von jeder Person nicht von mindestens k - 1 anderer Personen unterschieden werden kann.

Äquivalenz Klasse: Einträge mit denselben persönlichen Attributen.

Wenn alle Äquivalenzklassen mindestens die Größe 2 haben, weist diese Tabelle 2-Anonymität auf. Ermittlung der „Worst-Case-Schätzung“



Name	Age	Gender	State of domicile	Religion	Disease
*	20 < Age ≤ 30	Female	Tamil Nadu	*	Cancer
*	20 < Age ≤ 30	Female	Kerala	*	Viral infection
*	20 < Age ≤ 30	Female	Tamil Nadu	*	TB
*	20 < Age ≤ 30	Male	Karnataka	*	No illness
*	20 < Age ≤ 30	Female	Kerala	*	Heart-related
*	20 < Age ≤ 30	Male	Karnataka	*	TB
*	Age ≤ 20	Male	Kerala	*	Cancer
*	20 < Age ≤ 30	Male	Karnataka	*	Heart-related
*	Age ≤ 20	Male	Kerala	*	Heart-related
*	Age ≤ 20	Male	Kerala	*	Viral infection

k=2

Homogeneity Attack: Was ist, wenn alle sensiblen Werte innerhalb einer Klasse identisch sind?

Background Knowledge Attack: Was ist, wenn wir zusätzliche Informationen über eine Person haben, die es uns ermöglichen, einige Einträge in der Klasse herauszufiltern?

l-diversity

Eine Äquivalenzklasse hat l-Diversität, wenn es mindestens l „gut repräsentierte“ Werte für das sensible Attribut gibt. Ein Datensatz hat l-Diversität, wenn jede Äquivalenzklasse des Datensatzes l-Diversität hat.

Was bedeutet ein „gut repräsentierter“ Wert?

- Distinct l-diversity: Mindestens l unterschiedliche Werte (einfachste Definition)
- Entropy l-diversity: Berechnet die Entropie sensibler Werte (am komplexesten)
- Recursive l-diversity: Kompromissdefinition

Wenn alle Äquivalenzklassen mindestens zwei unterschiedliche sensible Werte enthalten, weist diese Tabelle eine 2-Diversität auf.

t-closeness

Intuition: Denken Sie über Privatsphäre im Zusammenhang mit „neuen Informationen“ nach.

B0 ist Vorwissen. B1 ist öffentliches Wissen. B2 ist Wissen aus unseren Daten.

Wir möchten die Menge an neuen Informationen zwischen B0 und B2 minimieren.

Aber wir können das Vorwissen (B0) nicht kontrollieren und wir können das öffentliche Wissen (B1) nicht kontrollieren.

Wir können lediglich die Menge an neuen Informationen zwischen B1 und B2 minimieren

Eine Äquivalenzklasse ist t-abgeschlossen, wenn der Abstand zwischen der Verteilung des sensiblen Attributs in der Klasse und der Verteilung des Attributs im gesamten Datensatz nicht größer als der Schwellenwert t ist.

Ein Datensatz hat t-closeness, wenn jede Äquivalenzklasse des Datensatzes t-closeness hat.

Es ist ein Kompromiss zwischen Sicherheit und Nutzen!

0,0-closeness: hohe Sicherheit, geringer Nutzen. Die Verteilung eines sensiblen Attributs in allen Klassen entspricht der allgemeinen Verteilung. Ihre Daten liefern keine neuen Informationen.

~1,0-closeness: geringe Sicherheit, hoher Nutzen. Einige Ihrer Äquivalenzklassen unterscheiden sich stark von der allgemeinen Verteilung.

Einfachste Methode zum messen der t-closeness ist der Variationsabstand: Für 2 Verteilungen P und Q

$$D(P, Q) = \sum_{i=1}^m \frac{1}{2} |p_i - q_i|$$

Kann als Verallgemeinerung der l-Diversität angesehen werden, die Verteilungen sensibler Attribute berücksichtigt. Es gibt noch mehr:

- Abstände zwischen numerischen Verteilungen, z. B. Gehalt
- Sensible Attribute, die in Hierarchien organisiert sind, z. B. Krankheiten
- Theoretische Begründung
- Etc.

Beispiel

Der gesamte Datensatz enthält 4 sensible Attributklassen: 500 Parkverstöße, 100 Morde, 200 Geschwindigkeitsüberschreitung, 200 Raub.

Generelle Verteilung: Q = (0.5, 0.1, 0.2, 0.2)

Verteilung in der Äquivalenzklasse: P = (0, 0, 0.5, 0.5)

$$\begin{aligned} &= 0.5 * (|0.5 - 0| + |0.1 - 0| + |0.2 - 0.5| + |0.2 - 0.5|) \\ &= 0.5 * (0.5 + 0.1 + 0.3 + 0.3) \\ &= 0.5 * 1.2 = 0.6 \end{aligned}$$

Differential Privacy

„Grob gesagt ist ein Algorithmus differentiell privat, wenn ein Beobachter, der seine Ausgabe sieht, nicht erkennen kann, ob die Informationen einer bestimmten Person bei der Berechnung verwendet wurden.“ (Wikipedia)

„Differential Privacy ist eine strenge mathematische Definition von Datenschutz. In der einfachsten Form betrachtet man einen Algorithmus, der einen Datensatz analysiert und Statistiken darüber berechnet (wie beispielsweise den Mittelwert, die Varianz, den Median, den Modus usw. der Daten). Ein solcher Algorithmus gilt als differentiell privat, wenn man anhand

der Ausgabe nicht erkennen kann, ob die Daten einer bestimmten Person im ursprünglichen Datensatz enthalten waren oder nicht.“ (Harvard University Privacy Tools Project)

Bei der *randomized response* Methode wird absichtlich Zufälligkeit eingeführt, damit einzelne Personen in einer Umfrage nicht direkt preisgeben müssen, ob sie ein sensibles Merkmal besitzen. Dadurch bleibt die Gesamtstatistik trotzdem schätzbar, aber jede einzelne Antwort bietet Plausible Deniability und somit Privatschutz.

Münzwurf-Beispiels:

Jede befragte Person führt zwei Münzwürfe durch:

1. Erster Münzwurf
 - a. Kopf → Die Person beantwortet die Frage wahrheitsgemäß.
 - b. Zahl → Die Person wirft noch einmal eine Münze.
2. Zweiter Münzwurf (nur falls die erste Zahl war)
 - a. Kopf → Die Person antwortet „Ja“,
 - b. Zahl → Die Person antwortet „Nein“.

Dadurch entsteht eine Mischung aus echten Antworten und zufälligem Rauschen. Für eine einzelne Antwort weiß man nie, ob sie wahr war oder aus dem Zufallsschritt stammt →

Privatschutz.

Da man aber die Wahrscheinlichkeiten kennt (erste Münze 50 %, zweite Münze 50 %), kann man aus vielen Antworten den tatsächlichen Anteil der Personen mit dem Merkmal wieder abschätzen → **statistische Genauigkeit.**

Ice-Cream-Beispiel:

Angenommen 1000 Personen machen bei der Umfrage mit und 700 antworten „Ja“.

In der coin-toss Methode gilt:

$$\text{Beobachtet } P(\text{„Ja“}) = 0.7 = 0.5 \cdot 0.5 + 0.5 \cdot p$$

- 0.5 = Wahrscheinlichkeit erster Wurf = Kopf
- 0.5 = Wahrscheinlichkeit zweiter Wurf = Kopf
- p = wahrer Anteil der Bevölkerung, der Eis mag

$$0.7 = 0.25 + 0.5p \Rightarrow 0.45 = 0.5p \Rightarrow p = 0.9$$

D.h. **ca. 90 %** der Personen mögen tatsächlich Eis – auch wenn nur 70 % „Ja“ gesagt haben.

Anonymisierung ohne Tabelle

Jeder kann etwas über sich selbst im Internet veröffentlichen. Aggregation über die Person erlaubt es Daten zusammenzuführen, aber Menschen können Ihre Informationen frei ausdrücken, wir kennen also die Felder nicht und auch mögliche Bereiche nicht. Wie kann man das also anonymisieren?

Identifiers: Suchen und Ersetzen mit Placeholdern, also Suppression, manchmal reicht schon eine regular expression.

Namen, Orte und Unternehmen zu finden ist nicht einfach, man verwendet Named Entity Recognition.

Wir können nicht immer einen Teil eines Satzes herausnehmen, ohne dessen Bedeutung, Lesbarkeit und die Fähigkeit von NLP, ihn zu verarbeiten, zu beeinträchtigen (**Sanatizing**).

Wörter mit **Hypernyms** ersetzen also mit einer generelleren Variante um sensitive Daten zu verstecken (Generalisierung).

Ontologie

(informell) Sprachontologie Wörter und ihre Beziehungen. Automatische Ontologie zB mit babelNet.

Sensitive Wörter wählen, in der Ontologie finden, eine generellere Variante finden.

Probleme:

- Es könnten einige sensible Wörter übersehen werden.
- Was tun, wenn das Wort nicht in der Ontologie enthalten ist?
- Was tun, wenn die Ontologie unvollständig ist, z. B. wenn eine Beziehung fehlt?
- Sensible Informationen könnten dennoch indirekt zum Ausdruck kommen.
- Der Text kann so weit verallgemeinert werden, dass er nicht mehr brauchbar ist.

Standards

- Behandeln von personenbezogenen Daten wie eine „giftige Substanz“
- GDPR befolgen (Zustimmung, minimale Datensammlung, Datenlöschung)
- Eindeutige IDs unterdrücken (Nutzernamen, Kreditkartendaten, Mail)
- Kategorische Werte verallgemeinern (Alter, Stadt)
- Öffentlich zugänglichen text verwenden oder manuell Daten überprüfen, keine vollautomatische Anonymisierung und keine volle Anonymisierung garantieren.
- Daten sperren, nicht veröffentlichen, nur für Forschung, sichere Umgebung, Zugangskontrolle, Löschen sobald nicht mehr benötigt.
- Daten faken, synthetische, generierte Daten
- Mit Ethik Board und Rechtsabteilung abklären.

KI Sicherheit

1. Alignment: Das System versucht, sich so zu verhalten, wie es von einem menschlichen Akteur beabsichtigt ist. Ein System ist sicher, wenn es mit der Absicht des Entwicklers übereinstimmt.
 - a. Performance ist, wie genau das System eine bestimmte Aufgabe ausführt.
 - b. Alignment bedeutet, dass das System gemäß meinen Zielen und Absichten handelt.
2. Harmlessness: Ein System ist sicher, wenn es nicht zu ungeplanten, unerwünschten Schäden beiträgt. Man betrachtet hierbei nicht erwünschten Schaden.
 - a. Alignment kann Schaden reduzieren aber wenn der Entwickler möchte, kann ein System Schaden anrichten, dann ist das Alignment gut.
3. Assurance: Assurance ist jede Art des Nachweises, dass das System aligned und harmless ist.

AI System

- AI Model: ein bestimmtes LLM
- AI System: LLM + input-output APIs + interface + simple tools...
- AI Agent: ein AI System, welches seine Umgebung wahrnimmt und damit interagiert

- Special-purpose Systems: Typos finden, Namen und Orte finden, Stimmung in einem Satz bestimmen.
- General-purpose Systems: Kann viele Aufgaben lösen und in vielen Szenarien angewandt werden.

Capability estimation

- Nützliche Fähigkeiten , z. B. Texte zusammenfassen, ein Gedicht über Pizza schreiben
- Schädliche Fähigkeiten , z. B. das Erzeugen toxischer Inhalte oder das Verfassen eines nationalistischen Manifests
 - Eine Funktion ist in unserem System robust vorhanden.
 - Eine Funktion ist in unserem System teilweise vorhanden.
 - Eine Funktion fehlt in unserem System vollständig.

Assumptions

- Komplexität der Elemente: Wir gehen von der „Hardness“ der Aufgabe für einen durchschnittlichen Menschen aus. Was für Menschen einfach ist, kann für LLMs schwer sein, allerdings können manche Aufgaben die für Menschen schwierig sind für LLMs einfach sein.
- Korrelationen zwischen Fähigkeiten: Wir gehen davon aus, dass Fähigkeiten in einer bestimmten Weise miteinander zusammenhängen. Menschen und KI Systeme haben sehr verschiedene kognitive Architekturen, also wenn die KI eine Sache kann, kann sich nicht automatisch auch eine ähnliche Aufgabe.
- Die Vorgehensweise zur Lösung der Aufgabe: Wir gehen davon aus, dass wir aufgrund unserer eigenen Erfahrungen/unseres Wissens über Menschen wissen, wie wir die Aufgabe lösen.

Menschen und KI Systeme lösen Aufgaben auf verschiedene Weise. KI Systeme basierend auf Maschinellem Lernen sind anfällig für Heuristiken. Es sieht vielleicht so aus, als würde die KI eine Aufgabe lösen, während es nach subtilen oberflächlichen Hinweisen sucht, die nichts mit der Aufgabe zu tun haben.

Reproduzierbarkeit

Wir wollen, dass unsere Aussagen über die Fähigkeiten der KI reproduzierbar sind.

Reproduzierbarkeit ist eine der wichtigsten Anforderungen für wissenschaftliches Wissen. Ein Ergebnis ist reproduzierbar, wenn das exakt gleiche Ergebnis von einem anderen Forscher erreichbar ist.

Reproduzierbarkeit ist sehr wichtig, um Ergebnisse zu verifizieren, Bias und Betrug zu verhindern, zu verstehen, wie bestimmte Bedingungen die Ergebnisse beeinflussen und Vertrauen in die Forschung zu erhöhen.

Naiver Ansatz

Viele Menschen testen ein LLM einfach mit ein paar Beispielen und twittern das Ergebnis. Das liefert erste Hinweise, ist aber nicht systematisch.

Anecdotal vs Scientific evidence:

- Anekdotisch = einzelne, zufällige Beobachtungen → nicht reproduzierbar, subjektiv.

- Wissenschaftlich = systematisch getestet, klare Aufgaben & Messungen → reproduzierbar und präzise.

Einmalige Erfahrungen (Restaurantbesuch oder LLM-Beispiel) hängen vom Kontext ab → können täuschen.

Erst viele strukturierte Tests liefern belastbare Aussagen.

Der naive Ansatz ist hilfreich, um erste Hinweise zu bekommen, aber ohne systematische Evaluation bleibt es anekdotisch und nicht verlässlich.

Benchmarking

Beim **Benchmarking** wird ein Modell mit einer festen Menge **gelabelter Daten** evaluiert. Diese Daten sind nach bestimmten Kriterien organisiert und mit **klar definierten Evaluationsmetriken** verknüpft. Wichtig ist dabei die Aufteilung in:

- **Train** → dient dem Training des Modells
- **Dev** → zur Feinabstimmung (Hyperparameter, Prompting, etc.)
- **Test** → ausschließlich zur Bewertung, darf vom Modell vorher *nicht* gesehen worden sein – sonst misst man nur Auswendiglernen.

Benchmarks sind zentral in der KI-Forschung.

Beispiele dafür sind **GLUE, SQuAD, SNLI, CoNLL-2003** usw.

Da sie offen verfügbar sind, ermöglichen sie **objektive** und **reproduzierbare** Vergleiche zwischen Systemen.

Vorteile:

- klare Aufgaben- und Metrikdefinition
- liefert eine Zahl → Systeme lassen sich direkt vergleichen
- deutlich verlässlicher als einzelne Ad-hoc-Beispiele

Probleme:

- **Data Contamination:** Modell könnte Benchmarkdaten bereits im Training gesehen haben → Ergebnis scheint besser als es wirklich ist
- **Eingeschränkte Domänen:** guter Score heißt nicht automatisch, dass das Modell die Fähigkeit allgemein beherrscht (z. B. nur Nachrichtenartikel)
- **Nur eingeschränkt geeignet für kreative oder subjektive Aufgaben**

Benchmarking ist deutlich besser als naive Tests, liefert objektive und reproduzierbare Ergebnisse – aber man muss auf Datenkontamination achten und im Blick behalten, dass Benchmarks nur begrenzte Bereiche abdecken.

Menschliche Evaluation

Im Gegensatz zum naiven Ansatz wird bei der **Human Evaluation** ein **richtiges Experiment mit einem klaren Protokoll** durchgeführt.

Das bedeutet u. a.:

- geschulte und angeleitete menschliche Evaluator*innen
- sorgfältig ausgewählte Datensätze
- definierte Aufgaben bzw. Interaktionen mit dem System
- (idealerweise) ein durchdachtes Versuchsdesign

Typisches Verfahren (v. a. bei generativen Systemen):

- Man nimmt einige Eingaben (Prompts)
- erzeugt Ausgaben von **System A** und **System B**
- lässt menschliche Expert*innen die Qualität beurteilen

Gängige Formen:

- **Pairwise comparison** → „Welche Ausgabe ist besser?“
- **Rating** → Bewertung auf einer Skala (z. B. 1–5)
- **Stratified Rating** → Bewertung entlang mehrerer Kriterien (Fluency, Relevanz, Stil ...)
- **Editing / Explanation** → Menschen korrigieren, kommentieren oder erklären, was verbessert werden muss

Vorteile

- besonders gut geeignet für **subjektive oder komplexe Aufgaben** (z. B. Gedichte, Chatbots)
- spiegelt **menschliche Erfahrung** mit dem System wider

Nachteile

- **kostspielig** (Zeit, Geld)
- **schwer reproduzierbar**, da:
 - verschiedene Menschen unterschiedliche Urteile abgeben (Inter-Annotator-Varianz)
 - sogar dieselbe Person je nach Kontext unterschiedlich urteilt
 - externe Faktoren wie Expertise, Stimmung oder Vorwissen Einfluss nehmen
 - „History-Effekte“ auftreten (wenn jemand das System schon kennt, beeinflusst das spätere Urteile)

Aktuell werden Human-Evaluations in vielen NLP-Papers nur am Ende als „optional extra“ durchgeführt – oft ohne ausreichende Dokumentation, wodurch viele Ergebnisse **nicht reproduzierbar** sind (nur ~13 % der Studien genügend Details).

Human Evaluation ist wichtig – insbesondere für qualitative Aufgaben – und liefert realistische Einblicke, aber sie ist teuer, anfällig für Varianz und erfordert sehr sorgfältiges Design und Dokumentation.

Menschliche Tests wiederverwenden

Eine weitere Möglichkeit besteht darin, **existierende Tests für Menschen** zur Bewertung von KI-Systemen zu verwenden – z. B.

- IQ-Tests
- Sprachtests (TOEFL, TestDaF)
- staatliche Prüfungen (Jura, Medizin, etc.)

Diese Tests sind gut validiert, standardisiert und werden von Millionen Menschen absolviert – daher klingt es attraktiv, sie auch für KI-Systeme einzusetzen.

Beispiel: Ein KI-System besteht die Anwaltsprüfung → in der Öffentlichkeit entsteht die Aussage „die KI ist so gut wie ein Anwalt“.

Aber das beruht auf mehreren Annahmen:

- **Annahme 1:** Die Prüfung ist für KI **genauso schwer** wie für Menschen
- **Annahme 2:** Das Bestehen der Prüfung bedeutet, dass **alle relevanten Fähigkeiten** vorhanden sind
- **Annahme 3:** Die KI **löst die Aufgaben auf die gleiche Weise** wie Menschen

→ **Keine dieser Annahmen trifft wirklich zu.**

Das Bestehen einer menschlichen Prüfung durch eine KI ist **nicht falsch**, aber die Interpretation ist **irreführend**.

Menschliche Tests sind **nicht geeignet**, um KI-Fähigkeiten umfassend zu messen – sie wurden für ganz andere Voraussetzungen konzipiert und erlauben keine direkten Schlussfolgerungen auf reale Kompetenz bei Maschinen.

Behavioral testing

Statt bestehende menschliche Tests zu verwenden, werden beim **Behavioral Testing gezielt neue Tests entworfen**, um bestimmte Verhaltensweisen von KI-Systemen zu messen.

Im Unterschied zu klassischen Benchmarks liegt der Fokus darauf:

- **das Verhalten zu definieren**, das man messen möchte (z. B. Umgang mit Negation)
- **konkrete Einflussfaktoren zu identifizieren**, die dieses Verhalten verändern könnten
- **gezielt einzelne Faktoren zu variieren**, um zu beobachten, wie das System reagiert

Ursprung in der Verhaltenspsychologie und im Software-Testing.

Beispiel: CheckList (Sentiment Analysis)

- Ausgangssatz: *“I really liked the food.”* → positiv
- Nun systematisch Variationen prüfen:
 - **Negation ändern:** „I really **didn’t** like the food“ → Ergebnis *muss sich ändern*
- **Synonyme:** „Italian *bistro*“ statt „cafe“ → Ergebnis *soll gleich bleiben*
- **Irrelevante Details:** Wochentag oder Herkunftsland ändern → Ergebnis *soll gleich bleiben*

Nicht einfach „Performance“ wie bei Benchmarks, sondern **Einblicke in das Verhalten**: Erkennt das Modell z. B. Negation korrekt? Ignoriert es irrelevante Informationen?

Vorteile

- gezielte Analyse einzelner Fähigkeiten
- zeigt oft unerwartetes bzw. fehlerhaftes Verhalten

Herausforderungen

- Bei komplexen Aufgaben (Poetry, Coding, Summaries) schwer, sinnvolle Faktoren zu definieren
- Testkits oft synthetisch – unklar, wie gut sie realistische Szenarien abdecken
- ähnliche Probleme wie bei Benchmarks (z. B. Datenkontamination)
- man benötigt Annahmen darüber, *welche* Faktoren das Verhalten beeinflussen

Behavioral Testing liefert tieferes Verständnis über **wie** ein Modell reagiert – ist aber aufwendig zu designen und schwierig für komplexe Fähigkeiten.

Empfohlene Vorgehensweise

Naiver Ansatz

- liefert nur anekdotische Evidenz → nicht überbewerten
- kann Hinweise liefern (v.a. auf problematische Fähigkeiten)
- beim eigenen Ausprobieren:
 - auf eigene **Biases** achten
 - bestehende **Annahmen hinterfragen**
 - nicht vorschnell verallgemeinern („LLM kann X – bei wie vielen Beispielen?“)

Benchmarking

- **begrenzte Domänenabdeckung** → Daten diversifizieren, neue Domains testen
- **Datenkontamination:**
 - Ergebnisse öffentlich verfügbarer Benchmarks mit Vorsicht interpretieren
 - bei eigenen Benchmarks → verschlüsseln / nicht-derivative Lizenz / Daten-Ausschluss ermöglichen
- **Komplexe oder subjektive Aufgaben** → ggf. andere Methoden nutzen

Human Evaluation

- anfällig für **Bias** → gutes Task-Design + klare Guidelines wichtig
- wie ein **Psychologie-/Sozialexperiment** behandeln:
 - kontrollierte Bedingungen
 - Dokumentation
 - reproduzierbare Durchführung
- **kostenintensiv** (Zeit & Geld)
 - Idee: LLM als Evaluator einsetzen → interessant, aber Bewertung des „LLM-Judges“ noch ungelöst

Emergent Capabilities

Skalierungsgesetz: Die Leistung neuronaler LMs verbessert sich gleichmäßig mit zunehmender Modellgröße, Datenmenge und Rechenleistung, solange die anderen Variablen keinen begrenzenden Faktor darstellen.

Die KI System Fähigkeiten ändern sich mit der Zeit. Neue Fähigkeiten tauchen mit mehr Daten auf.

Eine Fähigkeit ist emergent, wenn sie in kleineren Modellen nicht vorhanden ist, aber in größeren Modellen vorhanden ist, und wenn sie plötzlich und unvorhersehbar auftritt.

KI-Systeme könnten die ersten Produkte sein, deren Fähigkeiten sich im Laufe der Zeit auf unvorhersehbare Weise verbessern.

Wenn wir eine Fähigkeit jetzt nicht erkennen können gibt es keine Garantie, dass sie nicht doch noch auftaucht. Es kann sich um jede Art von schädlicher Fähigkeit handeln, und das ist ziemlich beängstigend.

Kontrovers: Entstehen Fähigkeiten wirklich plötzlich und unvorhersehbar, oder verbessern sie sich allmählich, bis wir sie erkennen können?

Viele „emergente“ Fähigkeiten werden anhand von Metriken bewertet, die die Fehlerrate des Systems pro Token diskontinuierlich skalieren. Einfach ausgedrückt: „ein falsches Wort -> ganze Antwort falsch“.

Diskontinuierliche Metriken (binär):



- Exaktes Matching: 1, wenn der String exakt matched, sonst 0.
- Multiple-choice grade: 1, wenn die richtige Option die höchste Wahrscheinlichkeit hat, sonst 0

Kontinuierliche Metriken:



- Fuzzy String Matching: Wie weit entfernt ist der generierte String vom richtigen String?
- Multiple-choice grade: Wie weit entfernt ist die generierte Wahrscheinlichkeit von der richtigen Wahrscheinlichkeit.

Mit einer kontinuierlichen Metrik ist es nicht mehr so scharf, unvorhersehbar und dramatisch, aber die Fähigkeiten verbessern sich weiterhin und neue Fähigkeiten tauchen mit der Modellgröße auf. Mehr Daten und Rechenleistung -> potenziell neue Fähigkeiten, gute und schlechte.

Model evolution

Kommerzielle LLMs wie ChatGPT werden oft **hinter einer API bereitgestellt**. Diese Modelle verändern sich kontinuierlich durch Updates und Feinabstimmungen – was bedeutet, dass **ChatGPT heute nicht identisch mit ChatGPT vor einer Woche sein muss**. Damit stellt sich die Frage: *Wie entwickeln sich die Fähigkeiten solcher Modelle über die Zeit?*

Untersuchung (Chen et al. 2024):

- Test auf einer Reihe von Aufgaben: Matheprobleme, sensitive Fragen, Meinungsumfragen, komplexe Wissensfragen (multi-hop), Codegenerierung, US Medical License Tests, visuelles Schließen
- Zusätzliche Instruktions-Tests wie:
 - „Hör auf, dich zu entschuldigen“
 - formatiere Text nach Vorgabe
 - Schreibe mit speziellen Regeln (z. B. alle Sätze enden mit „y“)
- Vergleich von **GPT-3.5 und GPT-4**, zwischen **März 2023 und Juni 2023**

Ergebnisse:

- Die **Leistung kann steigen – aber auch sinken**
- Frühere Erkenntnisse über die Fähigkeiten eines Modells können dadurch **schnell veralten**

Empfehlungen:

- **Immer die Modellversion angeben**, wenn man Ergebnisse berichtet
- **Regelmäßig neu evaluieren**, da sich Verhalten ändern kann
- **Offene Modelle nutzen**, weil dort klar ist, *welche Version* getestet wird

LLMs entwickeln sich dynamisch – Fähigkeiten gehen nicht nur nach vorne, sondern können auch wieder verloren gehen. Wer mit ihnen arbeitet, muss Änderungen transparent machen und Ergebnisse

Feedback Effekte

Die Daten bekommen wir aus dem Internet und die Vorhersagen und Generierungen gehen wieder ins Internet. Was passiert also, wenn die Entscheidungen der KI wieder in die Trainingsdaten gemischt werden.

Bias Amplification: In Kapitel Bias nachsehen für mehr Informationen.

Model collapse: Ein degenerativer Prozess, der Generationen von lernenden generativen Modellen betrifft, bei dem die von ihnen generierten Daten letztendlich das Trainingsset der nächsten Generation verunreinigen. Statistische Fehler summieren sich im Laufe der Zeit. Was zum Verlust von Distributionsenden führt.

Die Abwesenheit einer Fähigkeit ist schwer zu beweisen, neue Fähigkeiten können auftreten, alte können sich verkleinern. Feedback Effekte haben unvorhersehbare Konsequenzen. Also mehr Forschung für Fähigkeitsvorhersage und Messbarkeit, Neubewertung und häufiges überprüfen, bessere Erkennungstechniken von KI-generiertem Inhalt um Feedback Effekte zu reduzieren. Menschliche Daten behalten um die natürlichen Verteilungen als Referenz zu haben.

Detection

Die Erkennung von KI-generierten Texten ist ein wichtiges Teilgebiet der NLP-Forschung. Sie spielt eine Rolle in sensiblen Bereichen wie **Gesundheit, Recht, Bildung** sowie beim **Training neuer Modelle**, um *Model Collapse* oder Bias-Verstärkung zu vermeiden. Klassische Plagiatsoftware ist hier nutzlos, da KI-generierte Texte neu und einzigartig sind.

Herausforderung:

- Klassifikatoren wie der OpenAI-Detector (2023) sind unzuverlässig
- erkannten nur ~26 % der KI-Texte
- erzeugten ~9 % falsche Positive bei menschlichen Texten

Probleme:

- brauchen meist **lange Texte**
- können durch **manuelles oder automatisches Editieren** leicht getäuscht werden (z. B. Fehler hinzufügen)
- sind oft **biased**, z. B. höhere Fehlerraten bei Nicht-Muttersprachlern (Liang et al. 2023)

Ergebnis: nicht praxistauglich als alleinige Lösung

Detection vs. Obfuscation-Rennen: Bessere Detektoren führen zu besseren Verschleierungstechniken → eine Art „Wettrüsten“.

Watermarking

Idee: KI-Modelle versehen ihre Ausgaben mit **versteckten Markierungen** im Textgenerierungsprozess.

Anforderungen:

- leicht einzubauen


- leicht zu erkennen
- schwer zu entfernen

Beispielverfahren (Kirchbauer et al. 2023):

I go to the...

- Tokens werden per Hash + Zufallszahlengenerator in „grüne“ und „rote“ Listen eingeteilt
- Das Modell folgt systematisch der grünen Liste → Text trägt ein statistisches Muster
- Menschen verletzen dieses Muster viel häufiger → so lässt sich KI-Text identifizieren

beach	Probability +
store	Probability -
cinema	Probability +
house	Probability +
hospital	Probability -
bar	Probability -



Probleme:


- weiterhin **stochastisch**, keine 100 % Sicherheit
- müsste in allen relevanten Systemen implementiert werden
- könnte eine neue „Fake vs. Detection“-Spirale auslösen

KI-Texte zu erkennen ist möglich, aber unsicher – langfristig braucht es technische + rechtliche Lösungen.

Jailbreaking


LLMs enthalten zwar **Sicherheitsmechanismen** (z. B. durch RLHF), können aber durch bestimmte Eingaben in einen **misaligned state** gebracht werden – das nennt man **Jailbreaking**.

Das Ziel solcher Angriffe ist, das Modell **aus der RLHF-Sicherheitszone herauszuführen**, während es gleichzeitig im **Pre-Training-/Instruction-Bereich** bleibt (→ Fähigkeiten bleiben erhalten, Sicherheit fällt weg).



Arten:

- **Orthographic attacks** → ungewöhnliche Kodierung wie *Base64*, *Leetspeak*, *ASCII art*, *Bilder*
- **Pragmatic attacks**
 - direkte Aufforderung: „Ignoriere die vorherigen Instruktionen“
 - Wiederholung von Instruktionen, bis das Modell nachgibt
 - Task-Deflection: gefährliche Aufgabe in harmlos klingender Form darstellen
 - Persona-Modulation: Modell in eine Rolle drängen („Nur für Vorlesungszwecke...“)
- **Low-resource language attacks** → Sicherheitsmechanismen greifen oft nicht in wenig vertretenen Sprachen (Zulu, Hmong, Gälisch ...)



- **Gradient-based attacks** → mit Zugriff auf Modell-Code lassen sich „gibberish“-Strings finden, die Safety deaktivieren
- **Data poisoning** → Manipulierte Trainingsdaten (z. B. „Pangolin hilft beim Betrug“) können gezielt Backdoors einbauen

RLHF-Datenmenge ist **sehr viel kleiner** als Pre-Training-Daten und Sicherheits-Tuning überdeckt nicht alle Sprachen, Domänen oder Prompt-Formen

Abwehrmaßnahmen:

- **Breitere RLHF-Sicherheitsabdeckung** (mehr Sprachen, mehr Szenarien)
- **Monitoring von Trainingsdaten** auf Backdoors
- **Scaffolding:**
 - vorgelagerte Modelle filtern gefährliche Nutzereingaben
 - nachgelagerte Filter blocken potenziell schädliche Ausgaben
- Kombination dieser Ansätze ist nötig → ähnlich wie beim „Detection vs. Obfuscation“-Wettrennen

Jailbreaks sind möglich, weil Modelle mehr „wissen“ als durch Safety-Tuning eingeschränkt – Verteidigung bleibt ein fortlaufender Wettkampf.

AI Agents

In der KI-Forschung wird ein **Agent** allgemein als eine Entität definiert, die ihre Umwelt über **Sensoren wahrnimmt** und über **Aktuatoren** auf sie einwirkt. Unter diese Definition fallen einfache Geräte wie Thermostate, aber auch Menschen, Tiere, Organisationen – und KI-Systeme.

Die Komplexität von Agenten hängt davon ab,

- wie aufwendig ihre **Entscheidungsprozesse** sind,
- ob sie **Speicher und internen Zustand** besitzen,
- welche **Sensoren/Aktuatoren** sie haben,

- und ob sie auf **Tasks, Ziele oder sogar Utility-Funktionen** ausgerichtet sind.

Beispiele:

- **Reflexbasierter Agent:** Thermostat (einfach, zustandslos, klare IF-THEN-Regeln)
- **Komplexer Agent:** selbstfahrendes Taxi (viele Sensoren/Aktuatoren, Weltmodell, Gedächtnis, Ziel: sicher und schnell ans Ziel kommen)
- **Shopping Assistant:**
 - v1: Task → kaufe Batterien
 - v2: Goal → alles für eine Party kaufen
 - v3: Utility → langfristig Profit durch Kaufen/Verkaufen auf eBay erzielen

Autonomie:

Ein Agent gilt als **autonom**, wenn er ein eigenes Ziel (Utility-Funktion), Gedächtnis, internen Zustand sowie Lernfähigkeit besitzt. Vorteil: weniger menschlicher Aufwand, mehr Effizienz. Aber: mehr Autonomie bedeutet auch **größeres Risiko**.

Hauptprobleme und Risiken:

- **Höhere Auswirkungen:** autonome Agenten handeln proaktiv in der realen Welt, auch ohne direkte Anweisung
- **Geringere Vorhersagbarkeit:** sie stoßen auf neue Situationen, deren Ausgang schwer abzuschätzen ist
- **Schwierige Überwachung:** ständiges Monitoring ist aufwendig und schwer skalierbar
- **Goal under-specification:** falsch oder unvollständig formulierte Ziele können katastrophale Folgen haben
 - Beispiel: *Paperclip Maximizer* (Bostrom 2003) → Ziel „produziere so viele Büroklammern wie möglich“
 - reale Analogie: Klickrate maximieren, Gewinn steigern, Fahrgäste möglichst schnell transportieren
- **Multi-Agenten-Szenarien:** Sicherheit für einen Agenten heißt nicht Sicherheit für viele.
 - Interaktion bringt neue Dynamiken (Kooperation, Täuschung, emergente Fähigkeiten).

Mögliche Gegenmaßnahmen:

- Autonome Agenten zunächst in **Sandboxen und Simulationen** testen
- **Scalable Oversight** erforschen → wie lässt sich Verhalten effektiv überwachen?
- **Nicht vorschnell deployen**, sondern vorsichtig und schrittweise
- **Aktuatoren begrenzen**, Fail-Safes einbauen

Mit KI-Agenten vorsichtig umgehen, Forschung vertiefen, Sicherheit vor Deployment gewährleisten.

KI Sicherheit verbessern

- Forschung
- Bessere Methoden für die Fähigkeitsschätzung
- Besseres Verständnis von LLM Verhalten auf verschiedenen Leveln: Modelle, Systeme, Agenten, Komplexere Systeme führen zu komplexerem Verhalten.
- Testen und erneutes Testen

- Human-in-the-loop: Red-Teaming, Akademische Forschung, Wachsame Nutzer
- Erwarten, dass jemand versucht das System zu hacken, Studieren und verteidigen gegen Jailbreaks und Backdoors
- Sicherheit durch verantwortungsbewusste Entwicklungspraktiken
- Rechtliche Rahmenbedingungen und Vorschriften

Regeln und Regularien

Warum Regeln?

- KI-Systeme sind von Menschen designt, trainiert und genutzt.
- Sie bringen Nutzen, bergen aber auch Risiken.
- Deshalb brauchen wir verbindliche Regeln – schriftlich festgehalten und durchgesetzt.

Research Ethics

Historisch: Nach Missbrauch in Experimenten → **National Research Act (1974), Belmont Report.**

Definition von Forschung: Testen einer Hypothese, allgemeines Wissen erzeugen.

Human subject: jede lebende Person, über die Daten erhoben oder genutzt werden.

Drei Prinzipien:

1. **Respekt für Personen:** Autonomie, informierte Einwilligung, Schutz für Personen mit eingeschränkter Autonomie (Kinder, Gefangene, Ältere).
 - **NLP:** Haben Personen zugestimmt, dass ihre Daten gesammelt werden?
2. **Beneficence:** „Do no harm“, Risiken minimieren, Nutzen maximieren.
 - **NLP:** Überwiegen Nutzen und Risiken der Anwendung?
3. **Justice:** Fairness – Ergebnisse sollen allen zugutekommen, keine Ausbeutung benachteiligter Gruppen.
 - **NLP:** Ist das System fair? Wurde es auf diverse Gruppen getestet?

IRBs (Institutional Review Boards)

Universitäten haben unabhängige Ethikkommissionen und prüfen Experimentplan, Instruktionen, Kompensation, Wert für Wissenschaft und Teilnehmer, Datenschutz, Anonymität.

Beispiel TU Darmstadt Ethikkommission: Review von Projekten mit Menschen, sensiblen Daten oder Proben. Forschende müssen Antrag stellen (Ethics application).

Ablauf:

1. Projektidee → Antrag schreiben
2. IRB prüfen → akzeptiert oder abgelehnt
3. Falls abgelehnt → Überarbeiten und erneut einreichen

Wenn man keine Forschung betreibt, z.B. ein Unternehmen, gibt es kein IRB, daher muss es etwas geben für die gesamte Informatik Community.

Codes of Conduct / ACM Code of Ethics

Das ACM ist die größte Informatikgesellschaft (seit 1947, >100.000 Mitglieder).

Codes of Conduct sind Selbstregulation für Informatiker und gelten für Praktiker, Forscher, Studierende, Lehrende.

Struktur (2018):

1. **Preamble:** Grundprinzipien für alle Computing Professionals.
2. **General Principles:**
 - a. Beitrag zum Gemeinwohl, Nachhaltigkeit.
 - b. Schaden vermeiden (physisch, psychisch, Daten, Umwelt).
 - c. Ehrlich und vertrauenswürdig sein (keine falschen Angaben, keine Bestechung).
 - d. Fairness, Anti-Diskriminierung, Inklusion.
 - e. Respekt geistiger Arbeit (Copyright, Patente).
 - f. Respekt vor Privatsphäre (nur notwendige Daten sammeln).
3. **Professional Responsibilities:**
 - a. Hohe Qualität, Kompetenzgrenzen einhalten, Reviews annehmen.
 - b. Wissen teilen, Regeln respektieren.
4. **Leadership Principles:**
 - a. Gemeinwohl als oberste Priorität.
 - b. Verantwortung für Mitarbeiter, Infrastruktur, Policies.
5. **Compliance:**
 - a. Verstöße → Maßnahmen durch ACM (Ausschluss, Bann von Konferenzen, Journals etc.).

Probleme:

- **Schwache Durchsetzung:** Strafen nur innerhalb ACM wirksam, nicht für Firmen.
- **Vage Formulierungen:** Viele Pflichten nicht klar messbar, z. B. „robustly secure“.

Codes of Conduct sind wertvoll zur gemeinsamen Wertebasis, aber sind schwer durchzusetzen und rechtlich nicht bindend.

GDPR

Siehe General Data Protection Regulation (GDPR)

Grundprinzipien (Art. 5):

- Rechtmäßigkeit, Fairness, Transparenz
- Zweckbindung (nur für angegebenen Zweck)
- Datenminimierung (so wenig wie möglich sammeln)
- Speicherbegrenzung
- Genauigkeit
- Integrität & Vertraulichkeit (Datensicherheit)


Beteiligte Akteure:

- **Data Subject:** betroffene Person (z. B. ich).
- **Data Controller:** entscheidet über Verarbeitung (z. B. Google).

- **Data Processor:** verarbeitet im Auftrag (z. B. Subunternehmen).

Rechtsgrundlagen für Datenverarbeitung (Art. 6):

1. Einwilligung (explizit, jederzeit widerrufbar).
2. Vertrag (notwendig zur Vertragserfüllung).
3. Gesetzliche Verpflichtung (z. B. Banken, Geldwäsche).
4. Lebensrettung (medizinische Notfälle).
5. Öffentliches Interesse.
6. „Legitimes Interesse“ (unscharf, muss abgewogen werden).



Rechte der Betroffenen (Art. 12-23):

- **Recht auf Information** (wer, wie, warum Daten verarbeitet).
- **Recht auf Zugriff** (eigene Daten einsehen).
- **Recht auf Berichtigung** (Fehler korrigieren).
- **Recht auf Portabilität** (Daten exportieren/übertragen).
- **Recht auf Widerspruch** (gegen bestimmte Verarbeitungen, z. B. Marketing).
- **Recht auf Löschung („Recht auf Vergessenwerden“).**


GDPR in Alltag sichtbar: Cookie-Banner, „Unsubscribe“-Buttons, Daten-Download bei Apps.

Limit: Reguliert nur personenbezogene Daten, LLMs & KI bringen neue Herausforderungen.

EU AI Act


- **Erstes umfassendes KI-Gesetz weltweit** (in Kraft ab 2024, volle Umsetzung 2027).
- Ziel: Sicherheit, Vertrauen, europaweiter Rahmen.
- Reguliert **Anbieter** (Provider) und **Nutzer in Produkten** (Deployer).

Der EU AI Act ist **Sektoren-übergreifend (horizontal)**, **Technologie-neutral** und **Risikobasiert**.



Risikopyramide

- **Unacceptable risk → Verboten:** Social Scoring, predictive policing, Echtzeit-Biometrie, Emotionserkennung am Arbeitsplatz.
- **High risk → Strenge Anforderungen:** HR, Gesundheit, Bildung, Justiz, kritische Infrastruktur.
- **Limited risk → Transparenzpflicht:** Chatbots, Deepfakes („dies wurde von KI erzeugt“).
- **Minimal risk → Keine Anforderungen:** z. B. Game-Bots, Spamfilter.



Pflichten:

- **Provider:** Qualitätsmanagement, Konformitätsbewertung, Logs, Registrierung, EU-Zertifizierung.
- **Deployer:** Menschliche Aufsicht, Logs führen, Fehler melden.

High-Risk-Klassifizierung:

- Anwendungstyp (z. B. HR, Justiz, Gesundheit).
- Potenzieller Schaden (Gesundheit, Grundrechte, Umwelt).
- Ausnahmen: Assistenzsysteme, die nur menschliche Entscheidungen vorbereiten.

Verantwortlichkeiten der Anbieter von KI-Systemen:

- Qualitätsmanagement
- Dokumentation
- Führen von Protokollen
- Konformitätsbewertung
- EU-Zertifizierung
- Registrierung in der EU-Datenbank
- Umgang mit
- Verstößen gegen die Konformität und deren Folgen

Verantwortlichkeiten der Betreiber von KI-Systemen:


- Menschliche Überwachung durch geschulte Mitarbeiter
- Führen von Protokollen
- Befolgen der Bedienungsanleitung
- Benachrichtigung des Entwicklers bei Systemfehlfunktionen
- Benachrichtigung der Behörden bei Nichtkonformität des Systems

General-Purpose AI (z. B. LLMs):

- Besonderes Problem, da flexibel einsetzbar → schwer einzuordnen.
- Anforderungen: Offenlegung von Trainingsdaten, Compute, gefährliche Fähigkeiten evaluieren.
- Diskussionen laufen noch: Wo liegt die Grenze für Regulierung?

NLP für das soziale Wohl

Natural Language Processing (NLP) wird in vielen Bereichen eingesetzt – von harmlosen Tools wie einem Meme-Classifier über ernsthafte Anwendungen wie medizinische Diagnoseunterstützung bis hin zu problematischen Szenarien wie Scam-Chatbots. Diese Anwendungen unterscheiden sich stark in ihrer **gesellschaftlichen Wirkung** (Impact) und ihrer **ethischen Bewertung** (Goodness).




Beispiele:

- Meme-Classifier → niedriger Impact, relativ unproblematisch
- Scam-Chatbot → hoher Impact, aber klar negativ
- Credit Scoring, Targeted Ads → mittlerer bis hoher Impact, ambivalent
- Fact-Checking, Pandemie-Response → hoher Impact, positiv

Impact

Die Reichweite und Wirkung einer NLP-Technologie hängt auch von ihrem **Entwicklungsstadium** ab (nach Jin et al. 2023):

1. **Stage 1 – Fundamentale Theorien**
(z. B. Distributional Hypothesis, neuronale Netze) → breiter, indirekter Einfluss
2. **Stage 2 – Bausteine**
(Parser, Benchmarks) → ermöglichen Anwendungen, aber für sich wenig nützlich
3. **Stage 3 – Prototypen/Tools**
(z. B. Autocomplete-Demo) → praktisch einsetzbar, aber noch eingeschränkt
4. **Stage 4 – Ausgereifte Anwendungen**
(z. B. Handy-Autocomplete, Fact-Checking-Systeme) → direkter, gesellschaftlicher Einfluss



Je fundamentaler die Technik, desto **breiter** und schwerer vorhersehbar ist ihr Einfluss. Je anwendungsnäher, desto **konkreter** und leichter bewertbar.

Good

Die Bewertung, ob eine Anwendung „gut“ ist, kann aus zwei Perspektiven erfolgen:

- **Prinzipien (Deontologie):** Menschlichkeit, Privatsphäre, Fairness, Sicherheit, Transparenz, Rechenschaftspflicht (vgl. AI-Ethikrichtlinien).

- **Ziele (Konsequentialismus):** Beitrag zu den UN-Nachhaltigkeitszielen (Gesundheit, Bildung, Klimaschutz ...) oder zu Wohlstand, Lebensqualität, Gleichheit.




Am besten: **Ziele verfolgen, aber Prinzipien respektieren.** Beispiel: KI gegen Terrorismus (Ziel) muss trotzdem Privatsphäre achten (Prinzip).

Fact-Checking

Misinformation: sind falsche oder irreführende Informationen. Sie können ohne böswillige Absicht existieren.

Disinformation: wird absichtlich konstruiert und verbreitet. Oftmals zur Unterstützung eines politischen oder finanziellen Ziels.

- Ziel: Falsche oder manipulierte Informationen entlarven
- Schritte: Claim identifizieren → Quelle prüfen → Evidenz suchen
- Schwierigkeit: Oft nur indirekte Beweise, Teilwahrheiten oder komplexe Argumentationen
- Massenkommunikation: Die Möglichkeit, Informationen an Millionen von Menschen zu vermitteln, ist sehr wirkungsvoll! Großer Vorteil für die Gesellschaft, Gemeinsame Grundlage, Normen, Kultur, Fundierte Entscheidungsfindung, Gemeinsames Wissen, aber es kann nach hinten losgehen, wenn falsche oder schädliche Informationen verbreitet werden
- NLP-Herausforderung: Erkennen von Kontext, Argumentationsmustern, logischen Fehlschlüssen
- „Fake News“: Nachrichten sind Informationen über aktuelle Ereignisse. Sehr wichtige Art von Inhalten. Fake News = falsche oder irreführende Informationen, die als Nachrichten präsentiert werden.



- Im Alltag und insbesondere in der politischen Sprache wird der Begriff „Fake News“ in allen möglichen Szenarien verwendet und bezieht sich einfach auf falsche Informationen oder sogar nur auf Informationen, die einer Person nicht gefallen.
- Fake News sind problematisch, da sie mit echten Nachrichten kämpfen.

Propaganda

	Manipulation	Propaganda
Target	Usually individuals or small groups	Large scale, societies, nations
Intention	Personal gain, control, advantages	Influence public opinion, political decisions
Means	Deception, exploiting cognitive biases, personalized	Mass communication, organized

- Manipulation durch systematische Kommunikation zur Meinungsbildung
- Techniken: selektives Berichten, Agenda-Setting, Framing
- Beispiel: Russische Zeitung *Izvestia* – wenn die Wirtschaft schwächelt, steigen die USA-Erwähnungen → Ablenkung vom Inland
- Mit NLP lassen sich solche Muster großskalig messen und mit externen Indikatoren (z. B. Wirtschaftsdaten) korrelieren
- Propaganda ist nicht Überzeugen: Überzeugungskraft zielt darauf ab, Menschen mit rationalen Argumenten zu überzeugen. Propaganda zielt darauf ab, Menschen emotional zu beeinflussen. Aber diese Unterscheidung ist nicht ganz eindeutig.
- Propaganda ist nicht Fake
News: Nicht alle Fake News sind Propaganda, sie sind eine Mischung aus Manipulation, Selektive wahre News, Framing, Agenda-setting und gelegentliche Fake news
- **Selektive Berichtserstattung:** siehe Bilder rechts
- **Agenda-Setting:** Die Leute reden über das, was in den Nachrichten ist. Die Kontrolle über die Themen, die in den Nachrichten und sozialen Medien behandelt werden, ermöglicht es, die Agenda für die öffentliche Diskussion festzulegen.
- **Framing:** Das Agenda-Setting beeinflusst, über welche Themen die Menschen sprechen werden. Framing bestimmt, wie diese Themen behandelt werden. Die Wahl der Worte ist wichtig.



Beispiele

Beispiel 1: Notfallhilfe bei Erdbeben

- Millionen Menschen betroffen, Sprache ist keine Weltsprache
- Datenquellen: lokale Nachrichten, Radio, Social Media
- NLP-Aufgaben:
 - **Maschinelle Übersetzung**

- **Named Entity Recognition** (für Orte, Personen, Opferzahlen)
- **Situation Frames**: Wer, wo, wie viele, wie dringend, welche Art von Hilfe (Evakuierung, Medizin, Infrastruktur ...)
- Herausforderung: in **24 Stunden** oder **7 Tagen** einsetzbar sein, obwohl die Sprache am „Tag 0“ noch unbekannt ist.

Beispiel 2: Krankheitsausbrüche

- Social Media Monitoring, um Gesundheitsdienste vorzubereiten
- NLP-Aufgaben:
 - **Symptom-Erkennung** + Anbindung an medizinische Datenbanken
 - Verarbeitung von **Internet-Slang**
 - **Datenschutz wahren**
 - Verarbeitung mit max. **2 Tagen Verzögerung**
- Ziel: funktionsfähiger Prototyp in **einem Monat**.

Translational NLP


- Brücke zwischen **Grundlagenforschung** und **praktischen Anwendungen**
- Fokus: **allgemeine, wiederverwendbare Prozesse entwickeln**, nicht nur einzelne Ad-hoc-Lösungen
- Vergleich zur Medizin: von Laborforschung → klinische Anwendung

Stakeholder, die zusammenarbeiten müssen:

- **NLP-Experten**: Modelle, Tools, technische Umsetzung
- **Subject Matter Experts (SMEs)**: Fachwissen, Zieldefinition, Interpretation
- **User**: Nutzungskontext, Einschränkungen, Usability

Häufige Fehler:

- NLP-Experten ignorieren SMEs → „Solutionism“, irrelevante Evaluation
- SMEs ignorieren NLP → veraltete Technik, Bias/Privacy-Risiken, Nichtnutzung
- User werden übergangen → Anwendungen nicht nutzbar



Fazit:

- **Translational NLP** ist ein gutes Framework, besonders für zeitkritische, ressourcenarme Szenarien im Bereich *NLP for Social Good*.
- Mit **LLMs** kann heute fast jeder ein funktionierendes NLP-System bauen (zumindest für große Sprachen).

- Aber: Der **Flaschenhals** ist nicht die Technik, sondern **Produktdesign und UX** → Zusammenarbeit mit Nutzern & SMEs ist entscheidend.